

P6 OpenClassrooms

Classifiez automatiquement des biens de consommation

Sommaire

4	-----
6-7	-----
8-12	-----
13-25	-----
26-31	-----
32	-----

Contexte

EDA / Preprocessing

Classification / Extraction des features texte

Classification / Extraction des features image

Classification supervisée

Conclusion

Détails technique

Étapes pour **analyser** les **descriptions textuelles** et les **images des produits**:

- Un **prétraitement** des données texte et image
- Une **extraction** de features
- Une **réduction** en 2 dimensions, afin de projeter les produits sur un graphique 2D, sous la forme de points dont la couleur correspondra à la catégorie réelle
- Une **analyse** du **graphique** afin de conclure, à l'aide des descriptions ou des images, sur la **faisabilité de regrouper automatiquement** des produits de même catégorie
- Une réalisation d'une **mesure pour confirmer ton analyse visuelle**, en calculant la similarité entre les catégories réelles et les catégories issues d'une segmentation en clusters

Classification / Extractions des features image:

- un algorithme de type SIFT / ORB / SURF ;
- un algorithme de type CNN Transfer Learning.

classification / Extractions des features texte:

- deux approches de type bag-of-words, comptage simple de mots et Tf-idf ;
- une approche de type word/sentence embedding classique avec Word2Vec (ou Glove ou FastText) ;
- une approche de type word/sentence embedding avec BERT ;
- une approche de type word/sentence embedding avec USE (Universal Sentence Encoder).

Contexte

L'entreprise "Place de Marché" souhaite développer un moteur de classification automatique de produits d'après leurs images et descriptions textuelles.

Mon rôle en tant que Data Scientist est de fixer et réaliser les objectifs suivants:

1. Etudier la faisabilité d'un moteur de classification automatique (image + texte)
2. Développer une solution de classification supervisée à partir des images
3. Expérimenter une API externe pour enrichir la base de produits

Classification / Extractions des features texte:

- deux approches de type bag-of-words, comptage simple de mots et Tf-idf ;
- une approche de type word/sentence embedding classique avec Word2Vec (ou Glove ou FastText) ;
- une approche de type word/sentence embedding avec BERT ;
- une approche de type word/sentence embedding avec USE (Universal Sentence Encoder).


EDA

7 categories, 150 produits par catégories



Catégories	Longueur des descriptions	Observation
Watches	~51 mots	Certaines catégories (ex : Watches) ont des descriptions très courtes → plus difficile à clusteriser.
Beauty and Personal Care	~59 mots	
Home Furnishing	~76 mots	
Baby Care	~78 mots	D'autres (Kitchen & Dining, Home Decor) ont des descriptions plus riches → celles-ci seront mieux séparées dans l'espace vectoriel.
Computers	~87 mots	
Home Decor & Festive Needs	~91 mots	
Kitchen & Dining	~94 mots	

DataFrame	
1050 entries, 15 columns	bool(1), float64(2), object(12)
Distribution des longueurs de descriptions	
moyenne ≈ 76 mots	
médiane = 44 mots (la moitié des produits ont moins de 44 mots)	
longueur minimum = 1 mot	
longueur maximum = 587 mots (des fiches très longues)	
forme très asymétrique → beaucoup de descriptions courtes, une longue traîne de descriptions très longues	
Les descriptions sont hétérogènes : certaines sont très détaillées, d'autres quasi inexistantes. Cela impactera la qualité du clustering basé sur du texte brut.	

preprocessing




Classification / Extractions des features texte: (bag-of-words) comptage simple / tf idf



Classification / Extractions des features texte: Word2Vec


Silhouette: 0.368 - ARI : 0.112



Classification / Extractions des features texte: Glove/FastText


Silhouette: 0.142 - ARI : 0.146

Clusters K-Means sur PCA (features glove)



Silhouette: 0.148 - ARI : 0.192


Clusters K-Means sur PCA (features FastText)



Classification / Extractions des features texte: BERT / USE


Silhouette: 0.172 - ARI : 0.567

Clusters K-Means sur PCA (features bert)



Silhouette: 0.162 - ARI : 0.264

Clusters K-Means sur PCA (features use)



Classification / Extractions des features texte: Conclusion

Objectif	Modèle à recommander
Classification ou regroupement par catégories réelles	BERT
Bonne alternative légère	USE
Clustering naturel (structure des données)	Word2Vec
A éviter pour des textes courts	TF-IDF / Bag-of-Words

partie image

Le but de cette partie est de vérifier la faisabilité de regrouper automatiquement des produits par catégorie en utilisant uniquement les images. On suit exactement la logique demandée dans le mail :

- . Prétraitement images
- . Extraction de features (SIFT > BoVW)
- . Réduction de dimension (PCA puis T-SNE) pour visualiser
- . Clustering (KMeans sur T-SNE ou PCA)
- . Mesures (ARI + matrice de confusion + rapport)

Création des labels à partir du nom des images

Affichage d'exemples d'images par label

Home Decor

45204a03550940bdc8e4703c07f550.jpg



d202ea988ab11f2327279093ac71975d.jpg



2c475daafe597ed93c1e27fcaa38d8cc.jpg



77f659d4d18381c991fb9210e05d9c1b.jpg



Computers

Watches

f242a2cf1525f7700770cf1262b4b660.jpg



4788f5466992da09024b8ffcc8a5cba4.jpg



Détermination et affichage des descripteurs SIFT



Nombre de Keypoints : 1270

Shape des descripteurs : (1270, 128)

BoVW

Création des cluster de descripteurs


MiniBatchKMeans

Obtenir des temps de traitement
raisonnables

Nombre de cluster estimés: 415

Création de 415 clusters de
descripteurs

traitement Kmean: 1.90 sec



Création des features des images

Création d'un histogramme




features image = histogramme image

Comptage pour une image du nombre de
descripteurs par cluster



im_features (nombre d'images et
(k) nombre de cluster: (350, 415)

création histogrammes: 0.48 sec

Réduction PCA / Visualisation 2D (T-SNE)




Affichage T-SNE (Clusters KMeans) + ARI



cluster

0	52
1	38
2	53
3	51
4	44
5	55
6	57

Matrice de confusion : catégories principales vs clusters



Conclusion

- Les images projetées via BoVW-SIFT + T-SNE montrent une structure, mais la séparation reste limitée.
 - Le score ARI obtenu (ex: ~ 0.08 sur T-SNE) indique un regroupement faible à modéré par catégorie principale.
 - Certaines catégories sont visuellement proches (ex : “Home Furnishing” vs “Home Decor”, etc.), ce qui explique le mélange.
- 
- Cette étape valide la démarche “approche classique” (SIFT/BoVW), et justifie l’étape suivante (CNN Transfer Learning) pour améliorer la représentation


Faisabilité (clustering)

L'objectif maintenant est de démontrer la faisabilité d'une classification supervisée ultérieure en vérifiant que les images de produits peuvent être séparées visuellement selon leurs catégories principales. Pour cela, nous utilisons une approche en deux temps :

1.Extraction de caractéristiques visuelles via un réseau CNN pré-entraîné (VGG16)

2.Analyse non supervisée des représentations obtenues par réduction de dimension et clustering

Si les catégories sont naturellement séparées dans l'espace des features, une classification supervisée aura de fortes chances de bien fonctionner.



Création du modèle CNN pré-entraîné

Conv2D → détecte des motifs visuels (bords, textures, formes)

MaxPooling → réduit la taille de l'image

Dense → couche fully-connected (raisonnement de haut niveau)

Le réseau VGG16 transforme chaque image en un vecteur de 4096 valeurs numériques qui représentent sa structure visuelle de haut niveau.

Ces vecteurs servent ensuite de base à toute l'analyse de similarité et de regroupement.

Model: "functional"

Layer (type)	Output shape	Param #
input_layer (InputLayer)	(None, 224, 224, 3)	0
block1_conv1 (Conv2D)	(None, 224, 224, 64)	1,792
block1_conv2 (Conv2D)	(None, 224, 224, 64)	36,928
block1_pool (MaxPooling2D)	(None, 112, 112, 64)	0
block2_conv1 (Conv2D)	(None, 112, 112, 128)	73,856
block2_conv2 (Conv2D)	(None, 112, 112, 128)	147,584
block2_pool (MaxPooling2D)	(None, 56, 56, 128)	0
block3_conv1 (Conv2D)	(None, 56, 56, 256)	295,168
block3_conv2 (Conv2D)	(None, 56, 56, 256)	590,080
block3_conv3 (Conv2D)	(None, 56, 56, 256)	590,080
block3_pool (MaxPooling2D)	(None, 28, 28, 256)	0
block4_conv1 (Conv2D)	(None, 28, 28, 512)	1,180,160
block4_conv2 (Conv2D)	(None, 28, 28, 512)	2,359,808
block4_conv3 (Conv2D)	(None, 28, 28, 512)	2,359,808
block4_pool (MaxPooling2D)	(None, 14, 14, 512)	0
block5_conv1 (Conv2D)	(None, 14, 14, 512)	2,359,808
block5_conv2 (Conv2D)	(None, 14, 14, 512)	2,359,808
block5_conv3 (Conv2D)	(None, 14, 14, 512)	2,359,808
block5_pool (MaxPooling2D)	(None, 7, 7, 512)	0
flatten (Flatten)	(None, 25088)	0
fc1 (Dense)	(None, 4096)	102,764,544
fc2 (Dense)	(None, 4096)	16,781,312

Total params: 134,260,544 (512.16 MB)



Trainable params: 134,260,544 (512.16 MB)

Non-trainable params: 0 (0.00 B)

None
Dimension embedding : (None, 4096)


Projection T-SNE (clustering) + ARI

T-SNE selon les vraies classes



df_tsne shape : (840, 4)

Matrice de confusion



Conclusion

contrairement à SIFT qui compare les textures similaires des images, CNN permet de reconnaître les même type d'objet des images.

Grâce à “Adjusted Rand Index”, l'ARI de 0.45 (0.08 SIFT) démontre que sans jamais lui dire ce qu'est une catégorie, le modèle regroupe naturellement les images selon leur classe métier dans près de la moitié des cas

l'approche fondée sur un réseau de neurones convolutif pré-entraîné produit des représentations de haut niveau qui structurent naturellement les données selon les catégories métiers.


Etape prochaine :

Classification supervisée:


- . Création du modèle de classification
- . Approche préparation initiale des images
- . Approche ImageDatagenerator avec data augmentation (flow)
- . Approche nouvelle par Dataset sans data augmentation
- . Approche nouvelle par Dataset avec augmentation intégrée au modèle


approche simple

Test Accuracy : 0.7952



test Loss : 0.9537







Approche ImageDatagenerator avec data augmentation

test Accuracy : 0.7619



test Loss 0.9531



Approche nouvelle par Dataset sans augmentation




test Accuracy: 0.7905

test Loss: 1.1132



Approche nouvelle par Dataset avec augmentation intégrée au modèle

test Accuracy : 0.8381



Conclusion

Conclusion comparative

Plusieurs approches de classification supervisée d'images ont été expérimentées à partir du modèle VGG16 en Transfer Learning.

L'approche baseline sans augmentation atteint une accuracy test d'environ 79 %, mais présente un surapprentissage notable, visible par l'écart entre performances d'entraînement et de validation.

L'utilisation de l'ImageDataGenerator avec data augmentation réduit ce surapprentissage mais au prix d'une baisse de l'accuracy brute, due à une plus grande difficulté d'apprentissage induite par les transformations d'images.

L'approche basée sur l'API Dataset de TensorFlow, plus récente, offre des performances similaires tout en optimisant le pipeline de chargement des données.

Enfin, l'intégration de la data augmentation directement dans le modèle via des couches dédiées fournit le meilleur compromis :

Meilleure généralisation

Réduction de l'overfitting

Accuracy test supérieure (~83 %)

Cette approche constitue donc la solution retenue pour la classification supervisée des images produits.

API OpenFoodFacts

créer de nouvelles catégories, enrichir la base de données

Nb produits retenus : 10

	foodId	label	category	foodContentsLabel	image
0	3560070962334	Miel de la Champagne	Petit-déjeuners, Produits à tartiner, Produits...	Miel de la Champagne (France).	https://images.openfoodfacts.org/images/produc...
1	3270271513050	Tripes mijotées à l'Ancienne et cuisinées à la...	Plats-cuisees,Plats préparés,Tripes	estomacs de boeuf (origine France), eau, oigno...	https://images.openfoodfacts.org/images/produc...
2	3282946015837	Nicolas Feuillatte	Boissons, Boissons alcoolisées, Vins, Vins fra...	Champagne, Contient des _sulfites_	https://images.openfoodfacts.org/images/produc...
3	3596710488803	Miel de fleurs de la Champagne	Petit-déjeuners, Produits à tartiner, Produits...	Miel de fleurs de la Champagne - Récolté en Fr...	https://images.openfoodfacts.org/images/produc...
4	3185370729960	Br MOË HANDON MOET & CHANDON CHAMPAGNE IMPERIA...	Getränke und Getränkezubereitungen, Getränke, ...	IMPERIAL LOOK BEHIND THE SCENES OF OUR MAISON ...	https://images.openfoodfacts.org/images/produc...
5	3049610004104	Veuve Clicquot Champagne Ponsardin Brut	Boissons et préparations de boissons, Boissons...	Champagne	https://images.openfoodfacts.org/images/produc...
6	3250391764426	Préparation de Rhubarbe de Champagne Ardenne	Aliments et boissons à base de végétaux, Alime...	Rhubarbe de Champagne Ardenne(65%), sucre de c...	https://images.openfoodfacts.org/images/produc...
7	3267851000116	Champagne Orgueil de France	Beverages, Alcoholic beverages, Wines, Sparkli...	Champagne	https://images.openfoodfacts.org/images/produc...
8	3359952005005	Champagne AOP, brut	Boissons, Boissons alcoolisées, Vins, Vins eff...	Champagne brut (_sulfites_)	https://images.openfoodfacts.org/images/produc...
9	3043700103821	Cordon Rouge	Boissons, Boissons alcoolisées, Vins, Vins fra...	Champagne (contient _sulfites_)	https://images.openfoodfacts.org/images/produc...

✓ CSV écrit : champagne_products_filtered_ingredients.csv